

Projeto - Análise de Componentes Principais

Emanuel Franklin Passos Simões

Sumário

1. Introdução	1
2. Carregando bibliotecas	2
3. Importando base de dados	2
4. Tratamento dos dados	2
5. Questão 1	4
6. Questão 2	6

1. Introdução

O projeto é composto por uma base de dados que contém 18 variáveis na escala Likert de 5 pontos e 201 respostas (mais informações em [professortp](#)). Ele consiste em uma pesquisa sobre “necessidade de cognição” de cada sujeito, e os objetivos são responder as seguintes perguntas:

1. Analise os dados para a necessidade de cognição usando componentes principais. Quanta variância é explicada pelo primeiro componente? Sua análise sugere que um único componente realiza um trabalho adequado de captação da necessidade de cognição? Justifique.
2. Os pesquisadores, em geral, formam a escala de cognição, adicionando os escores dos itens (itens de códigos reversos são subtraídos). Como essa medida se compara com o primeiro componente principal da análise no item “a”? Qual você usaria e por quê?

Para cumprir os objetivos, será preciso:

1. Importar e tratar os dados (transformar todos em numéricos e tratar missing values);
2. Realizar análise de componentes principais.

2. Carregando bibliotecas

```
if (!requireNamespace('pacman', quietly = TRUE)) {  
  install.packages('pacman')  
}  
  
pacman::p_load(tidyverse, GGally, ggcorrplot, pheatmap, factoextra, MatchIt, psych)
```

3. Importando base de dados

```
url <- 'https://www.professortp.com.br/est014/dados/COGNITION.txt'  
  
dados <- read.table(url, row.names = 1, header = TRUE)  
head(dados)
```

	C1	C2	C3	C4	C5	C6	C7	C8	C9	C10	C11	C12	C13	C14	C15	C16	C17	C18
1	1	3	4	4	3	4	3	4	4	3	4	3	4	4	3	2	2	2
2	2	4	1	1	2	1	4	2	2	4	4	3	2	2	4	2	1	4
3	4	4	1	1	1	3	1	3	2	4	5	1	5	4	5	2	2	4
4	3	1	4	5	4	3	3	3	5	1	1	2	3	5	1	5	5	3
5	4	4	2	2	1	4	2	2	1	4	5	1	4	2	4	1	1	2
6	5	5	1	1	1	5	1	3	1	5	5	1	5	5	5	1	2	4

4. Tratamento dos dados

```
str(dados)
```

```
'data.frame':  201 obs. of  18 variables:  
 $ C1 : int  1 2 4 3 4 5 3 3 4 4 ...  
 $ C2 : int  3 4 4 1 4 5 3 4 4 4 ...  
 $ C3 : int  4 1 1 4 2 1 1 1 1 2 ...  
 $ C4 : int  4 1 1 5 2 1 2 1 2 2 ...  
 $ C5 : int  3 2 1 4 1 1 2 1 2 1 ...  
 $ C6 : chr   "4" "1" "3" "3" ...  
 $ C7 : int  3 4 1 3 2 1 4 2 4 5 ...  
 $ C8 : int  4 2 3 3 2 3 3 3 3 2 ...  
 $ C9 : chr   "4" "2" "2" "5" ...
```

```

$ C10: chr  "3" "4" "4" "1" ...
$ C11: chr  "4" "4" "5" "1" ...
$ C12: int   3 3 1 2 1 1 2 1 2 1 ...
$ C13: int   4 2 5 3 4 5 3 3 4 3 ...
$ C14: chr  "4" "2" "4" "5" ...
$ C15: chr  "3" "4" "5" "1" ...
$ C16: chr  "2" "2" "2" "5" ...
$ C17: chr  "2" "1" "2" "5" ...
$ C18: chr  "2" "4" "4" "3" ...

```

Observa-se que algumas variáveis estão definidas como **chr** e não **int**. É preciso fazer essa transformação para prosseguir na análise, já que não é possível fazer cálculos com variáveis **chr**.

```

dados <- dados %>%
  mutate(across(everything(), as.integer))

```

Warning: There were 9 warnings in `mutate()`.

The first warning was:

i In argument: `across(everything(), as.integer)`.

Caused by warning:

! NAs introduzidos por coerção

i Run `dplyr::last\_dplyr\_warnings()` to see the 8 remaining warnings.

```
str(dados)
```

```

'data.frame': 201 obs. of 18 variables:
 $ C1 : int  1 2 4 3 4 5 3 3 4 4 ...
 $ C2 : int  3 4 4 1 4 5 3 4 4 4 ...
 $ C3 : int  4 1 1 4 2 1 1 1 1 2 ...
 $ C4 : int  4 1 1 5 2 1 2 1 2 2 ...
 $ C5 : int  3 2 1 4 1 1 2 1 2 1 ...
 $ C6 : int  4 1 3 3 4 5 1 3 4 3 ...
 $ C7 : int  3 4 1 3 2 1 4 2 4 5 ...
 $ C8 : int  4 2 3 3 2 3 3 3 3 2 ...
 $ C9 : int  4 2 2 5 1 1 2 3 1 2 ...
 $ C10: int  3 4 4 1 4 5 4 4 5 4 ...
 $ C11: int  4 4 5 1 5 5 4 5 5 5 ...
 $ C12: int  3 3 1 2 1 1 2 1 2 1 ...
 $ C13: int  4 2 5 3 4 5 3 3 4 3 ...
 $ C14: int  4 2 4 5 2 5 2 5 4 4 ...

```

```
$ C15: int  3 4 5 1 4 5 3 4 4 4 ...
$ C16: int  2 2 2 5 1 1 2 2 4 2 ...
$ C17: int  2 1 2 5 1 2 1 1 1 1 ...
$ C18: int  2 4 4 3 2 4 2 2 4 5 ...
```

Agora, será verificado a presença de missing values.

```
sum(is.na(dados))
```

```
[1] 14
```

Como há missing values, optou-se por imputar pela mediana, pois é menos pior do que imputar pela média ou moda.

```
for (j in names(dados)) {
  coluna <- dados[[j]]
  med <- median(coluna, na.rm = TRUE)
  coluna[is.na(coluna)] <- med
  dados[[j]] <- coluna
}
```

```
sum(is.na(dados))
```

```
[1] 0
```

5. Questão 1

Optou-se por fazer a análise utilizando matriz de covariancias, já que os dados estão na mesma escala.

```
acp = prcomp(dados)
summary(acp)
```

Importance of components:

	PC1	PC2	PC3	PC4	PC5	PC6	PC7
Standard deviation	2.6957	1.35050	1.31113	1.1897	1.14184	1.09111	1.0756
Proportion of Variance	0.3122	0.07835	0.07385	0.0608	0.05601	0.05114	0.0497
Cumulative Proportion	0.3122	0.39052	0.46436	0.5252	0.58117	0.63232	0.6820
	PC8	PC9	PC10	PC11	PC12	PC13	PC14


Standard deviation	1.03185	0.99950	0.94275	0.88022	0.85702	0.8202	0.77722
Proportion of Variance	0.04574	0.04291	0.03818	0.03328	0.03155	0.0289	0.02595
Cumulative Proportion	0.72776	0.77067	0.80885	0.84214	0.87369	0.9026	0.92853
	PC15	PC16	PC17	PC18			
Standard deviation	0.74556	0.67509	0.58362	0.55803			
Proportion of Variance	0.02388	0.01958	0.01463	0.01338			
Cumulative Proportion	0.95241	0.97199	0.98662	1.00000			

Os dados acima apresentam o desvio padrão de cada componente principal, a proporção da variância explicada e a proporção acumulada, respectivamente.

Conforme perguntado na questão 1, observa-se que a variância explicada pelo primeiro componente é 31,22%.

Para verificar se um único componente realiza um trabalho adequado de captação da necessidade de cognição, será feito o Scree Plot:

```
fa.parallel(dados, fa = "pc", n.iter = 1000)
```



Parallel analysis suggests that the number of factors = NA and the number of components =

Observa-se que um único componente realiza um trabalho adequado, visto que o primeiro componente está muito acima dos autovalores aleatórios (limite rígido), enquanto o segundo componente não falha, mas também não é tão informativo.

6. Questão 2

Enquanto a escala de cognição citada soma ou subtrai as respostas das perguntas, o método das componentes principais atribui pesos aos escores com base na correlação global entre as variáveis.

- Exemplo: Se uma pessoa marcou 4 na **C1**, soma 4 no índice.

Como ambas funcionam e a escala de cognição citada parece mais simples, eu usaria a soma simples.